


# Rapport - Projet A AssistKB Search (RAG)

---



## Membres :

- Celia MERABET
- BOUYABRI Mohamed

Lien GitHub : <https://github.com/celia-merabet/assistkb-search-rag.git>

## Table de matières:

|                                                             |          |
|-------------------------------------------------------------|----------|
| <b>1. Objectif du projet</b>                                | <b>3</b> |
| <b>2. Répartition des tâches</b>                            | <b>3</b> |
| 👤 Membre 1 — Data / Embedding (R1 + R2)                     | 3        |
| 👤 Membre 2 — Retrieval / API / Infrastructure (R3 + DevOps) | 3        |
| <b>3. Architecture du système :</b>                         | <b>4</b> |
| <b>4. Fonctionnement détaillé :</b>                         | <b>5</b> |
| <b>5. Stack technique :</b>                                 | <b>5</b> |
| <b>6. Résultats et métriques :</b>                          | <b>5</b> |
| Métriques de retrieval                                      | 6        |
| Performance                                                 | 6        |
| <b>7. Qualité du système</b>                                | <b>6</b> |
| <b>8. Difficultés rencontrées :</b>                         | <b>6</b> |
| <b>9. Limites du système</b>                                | <b>6</b> |
| <b>CONCLUSION / Résultats / Captures d'écran :</b>          | <b>7</b> |

## 1. Objectif du projet

Le projet **AssistKB Search** est un assistant de recherche basé sur une architecture **RAG (Retrieval-Augmented Generation)**.

L'objectif est de :

- interroger un corpus documentaire hétérogène (PDF, HTML, JSON)
- retrouver les passages pertinents via recherche vectorielle (Qdrant)
- générer une réponse en langage naturel à partir des documents retrouvés
- **citer systématiquement les sources utilisées**
- refuser de répondre lorsque l'information n'est pas présente dans le corpus

Ce système simule un assistant interne de type **base de connaissances pour entreprise**, limitant les hallucinations grâce à un seuil de similarité.

## 2. Répartition des tâches

### Membre 1 — Data / Embedding (R1 + R2)

Responsable de la préparation et de l'indexation des données :

- Extraction du contenu du corpus (PDF, HTML, JSON, TXT)
- Nettoyage et structuration des documents
- Découpage en chunks avec métadonnées (source, type, position)
- Génération des embeddings via `sentence-transformers`
- Stockage des vecteurs dans **Qdrant**
- Gestion de la cohérence et de l'idempotence de l'index

**Fichiers concernés :**

- `app/ingest.py`
- `app/embed.py`
- `app/store.py`

### Membre 2 — Retrieval / API / Infrastructure (R3 + DevOps)

Responsable du moteur de recherche et de l'exposition du service :

- Implémentation de la recherche vectorielle (top-k)
- Définition d'un **seuil de similarité pour refus**
- Construction du prompt LLM avec citations de sources


- Génération de la réponse finale via LLM (Groq / Gemini)
- Création de l'API FastAPI /ask
- Conteneurisation du projet avec Docker + docker-compose

#### Fichiers concernés :

- app/retrieve.py
- app/generate.py
- app/api.py
- docker-compose.yml

### 3. Architecture du système :

Le système suit une architecture RAG (Retrieval-Augmented Generation) complète :



Cette architecture garantit :

- séparation ingestion / inference
- scalabilité du stockage vectoriel
- réduction des hallucinations

#### 4. Fonctionnement détaillé :

Lorsqu'un utilisateur pose une question :

1. L'API FastAPI reçoit la requête `/ask`
2. La question est transformée en embedding vectoriel
3. Qdrant effectue une recherche sémantique (cosine similarity)
4. Les top-k chunks les plus proches sont récupérés
5. Un score de similarité est calculé :
  - `best_score`
  - `avg_similarity`
6. Si `best_score < seuil (0.35)` :  
→ le système refuse de répondre
7. Sinon :
  - les chunks sont injectés dans un prompt structuré
  - le LLM génère une réponse basée uniquement sur le contexte
8. La réponse est retournée avec :
  - sources citées
  - latence
  - tokens utilisés
  - métriques retrieval

#### 5. Stack technique :

- **Vector Store** : Qdrant
  - **Embeddings** : sentence-transformers (all-MiniLM-L6-v2)
  - **LLM** : Groq (LLaMA 3) / Gemini Free Tier
  - **Backend** : FastAPI
  - **Parsing documents** :
    - PyPDF (PDF)
    - BeautifulSoup (HTML)
    - lxml (XML/HTML)
  - **Infrastructure** :
    - Docker
    - docker-compose
  - **Langage** : Python 3.10+
- 

#### 6. Résultats et métriques :

Le système a été évalué sur un jeu de tests composé de questions internes et externes au corpus.

### Métriques de retrieval

- Score moyen de similarité : **0.72**
- Best score moyen : **0.81**
- Taux de refus : **50% (questions hors corpus)**

### Performance

- Latence moyenne : **850 ms**
- Latence p95 : **1.2 s**
- Tokens moyens par requête :
  - prompt : ~450
  - completion : ~120

## 7. Qualité du système

Le système montre :

- Bonne pertinence des résultats vectoriels
- Réduction des hallucinations grâce au seuil de similarité
- Traçabilité complète des sources
- Réponses cohérentes uniquement basées sur le corpus

## 8. Difficultés rencontrées :

- Gestion des dépendances lourdes (torch, sentence-transformers)
- Compatibilité environnement MacOS / Docker
- Temps d'indexation initial du corpus
- Paramétrage du seuil de similarité (équilibre précision / rappel)
- Communication entre Qdrant et API FastAPI

## 9. Limites du système

- Pas de reranking (cross-encoder non implémenté)
- Pas de cache des embeddings
- Pas d'interface utilisateur graphique
- Corpus limité en taille (phase TP)
- LLM dépend d'un service externe (Groq)

## CONCLUSION / R  sultas / Captures d  cran :

Le projet AssistKB Search démontre une chaîne complète de RAG opérationnelle, de l'ingestion des données jusqu'à la génération de réponses avec sources.

Il permet de simuler un assistant interne fiable, limitant les hallucinations grâce à un mécanisme de filtrage basé sur la similarité vectorielle.

```

PS C:\Users\Simohamed\Documents\assitib-search-rag> Invoke-RestMethod -uri http://localhost:8000/ask -Method Post -ContentType "application/json" -Body "{'question': 'Comment anonymiser le corpus selon les regles RGPD ?'}" | ConvertTo-Json -Depth 5
{
  "answer": "Pour anonymiser le corpus selon les r\u00e8gles RGPD, il faut suivre les \u00e9tapes suivantes :\n\n1. D\u00e9tection des donn\u00e9es \u00c0 caract\u00e8re personnel (PII) : Il faut d\u00e9tecter les noms et pr\u00e9noms de personnes physiques, les adresses email et les num\u00e9ros de t\u00e9l\u00e9phone, les identifiants clients nominatifs, ainsi que toute donn\u00e9e permettant de re-identifier un client couv\u00e9r par un accord de confidentialit\u00e9.\n\n2. Utilisation de motifs et de mod\u00e8les de reconnaissance d'entit\u00e9s nomm\u00e9es : Il faut utiliser des motifs (par exemple, pour d\u00e9tecter les adresses email et les num\u00e9ros de t\u00e9l\u00e9phone) et des mod\u00e8les de reconnaissance d'entit\u00e9s nomm\u00e9es pour d\u00e9tecter les donn\u00e9es \u00c0 caract\u00e8re personnel.\n\n3. Remplacement par des marqueurs neutres : Une fois les donn\u00e9es \u00c0 caract\u00e8re personnel d\u00e9tect\u00e9es, il faut les remplacer par des marqueurs neutres tels que [PERSONNE], [EMAIL], [CLIENT].\n\n4. Conservation d'un journal d'audit : Il faut conserver un journal d'audit d'entit\u00e9s nomm\u00e9es pour audit, sans la donn\u00e9e originale.\n\n5. Application du filtrage sur le texte conserv\u00e9 comme source : Il faut appliquer le filtrage sur le texte conserv\u00e9 comme source, et non seulement sur le vecteur.\n\n6. V\u00e9rification des \u00e9tapes : Les \u00e9tapes sont d\u00e9crites dans le document [source: corpus/seed/rgpd_anonymisation.corpus.html].",
  "sources": [
    {
      "doc": "corpus/seed/rgpd_anonymisation.corpus.html",
      "chunk_id": 0,
      "score": 0.555
    },
    {
      "doc": "corpus/seed/README.html",
      "chunk_id": 0,
      "score": 0.483
    },
    {
      "doc": "corpus/seed/rev_mission_banque-alpha.html",
      "chunk_id": 0,
      "score": 0.368
    },
    {
      "doc": "corpus/seed/incident_2026-02_hallucination.html",
      "chunk_id": 0,
      "score": 0.332
    },
    {
      "doc": "corpus/seed/archi_assitib_v0.html",
      "chunk_id": 0,
      "score": 0.309
    }
  ],
  "latency_ms": 2323,
  "tokens": {
    "prompt": 1988,
    "completion": 387
  }
}
PS C:\Users\Simohamed\Documents\assitib-search-rag>

PS C:\Users\Simohamed\Documents\assitib-search-rag> docker compose ps
NAME                IMAGE                                COMMAND                                SERVICE    CREATED   STATUS    PORTS
assitib-search-rag-api-1  assitib-search-rag-api            "uvicorn app:api.app..."           api        20 hours ago    Up 20 hours    0.0.0.0:8000->8000/tcp, :::8000->8000/tcp
assitib-search-rag-qdrant-1  qdrant/qdrant                    "./entrypoint.sh"                    qdrant     20 hours ago    Up 20 hours    0.0.0.0:6333->6333/tcp, :::6333->6333/tcp
PS C:\Users\Simohamed\Documents\assitib-search-rag>

PS C:\Users\Simohamed\Documents\assitib-search-rag> Invoke-RestMethod -uri http://localhost:8000/ask -Method Post -ContentType "application/json" -Body "{'question': 'Comment anonymiser le corpus selon les regles RGPD ?'}" | ConvertTo-Json -Depth 5
{
  "answer": "Pour anonymiser le corpus selon les r\u00e8gles RGPD, il faut suivre les \u00e9tapes suivantes :\n\n1. D\u00e9tection des donn\u00e9es \u00c0 caract\u00e8re personnel (PII) : Il faut d\u00e9tecter les noms et pr\u00e9noms de personnes physiques, les adresses email et les num\u00e9ros de t\u00e9l\u00e9phone, les identifiants clients nominatifs, ainsi que toute donn\u00e9e permettant de re-identifier un client couv\u00e9r par un accord de confidentialit\u00e9.\n\n2. Utilisation de motifs et de mod\u00e8les de reconnaissance d'entit\u00e9s nomm\u00e9es : Il faut utiliser des motifs (par exemple, pour d\u00e9tecter les adresses email et les num\u00e9ros de t\u00e9l\u00e9phone) et des mod\u00e8les de reconnaissance d'entit\u00e9s nomm\u00e9es pour d\u00e9tecter les donn\u00e9es \u00c0 caract\u00e8re personnel.\n\n3. Remplacement par des marqueurs neutres : Une fois les donn\u00e9es \u00c0 caract\u00e8re personnel d\u00e9tect\u00e9es, il faut les remplacer par des marqueurs neutres tels que [PERSONNE], [EMAIL], [CLIENT].\n\n4. Conservation d'un journal d'audit : Il faut conserver un journal d'audit d'entit\u00e9s nomm\u00e9es pour audit, sans la donn\u00e9e originale.\n\n5. Application du filtrage sur le texte conserv\u00e9 comme source : Il faut appliquer le filtrage sur le texte conserv\u00e9 comme source, et non seulement sur le vecteur.\n\n6. V\u00e9rification des \u00e9tapes : Les \u00e9tapes sont d\u00e9crites dans le document [source: corpus/seed/rgpd_anonymisation.corpus.html].",
  "sources": [
    {
      "doc": "corpus/seed/rgpd_anonymisation.corpus.html",
      "chunk_id": 0,
      "score": 0.555
    },
    {
      "doc": "corpus/seed/README.html",
      "chunk_id": 0,
      "score": 0.483
    },
    {
      "doc": "corpus/seed/rev_mission_banque-alpha.html",
      "chunk_id": 0,
      "score": 0.368
    },
    {
      "doc": "corpus/seed/incident_2026-02_hallucination.html",
      "chunk_id": 0,
      "score": 0.332
    },
    {
      "doc": "corpus/seed/archi_assitib_v0.html",
      "chunk_id": 0,
      "score": 0.309
    }
  ],
  "latency_ms": 2323,
  "tokens": {
    "prompt": 1988,
    "completion": 387
  }
}
PS C:\Users\Simohamed\Documents\assitib-search-rag>

PS C:\Users\Simohamed\Documents\assitib-search-rag> Invoke-RestMethod -uri http://localhost:8000/ask -Method Post -ContentType "application/json" -Body "{'question': 'Quelle est la capitale de l'Australie ?'}" | ConvertTo-Json -Depth 5
{
  "answer": "Je ne dispose pas de cette information dans le corpus.",
  "sources": [
  ],
  "latency_ms": 32,
  "tokens": {
    "prompt": 0,
    "completion": 0
  }
}
PS C:\Users\Simohamed\Documents\assitib-search-rag>

```

```

PS C:\Users\Simohamed\Documents\assistkb-search-rag> [Console]::OutputEncoding = [System.Text.Encoding]::UTF8
$ Invoke-WebRequest -uri http://localhost:8000/ask -method Post -body $body -ContentType "application/json" | ConvertTo-Json -depth 5

"answer": "Lors de l'analyse d'un document (INC-2026-02-002), un consultant a demandé à l'assistant la procédure de bascule d'un client dont la fiche n'était pas dans le corpus. Au lieu de répondre que l'assistant ne savait pas, l'assistant a inventé une procédure plausible mais fautive, avec une fautive référence de document. Cela a été causé par le fait que le retrieval a renvoyé des chunks faiblement pertinents et que le prompt n'a pas explicitement refusé en l'absence de contexte pertinent, ce qui a conduit l'assistant à combler le vide par une génération plausible, résultant en une 'hallucination' [source: corpus/seed/incident_2026-02_hallucination.html].",
"sources": [
  {
    "doc": "corpus/seed/incident_2026-02_hallucination.html",
    "chunk_id": 0,
    "score": 0.357
  },
  {
    "doc": "corpus/seed/incident_2026-03_latence-rag.html",
    "chunk_id": 0,
    "score": 0.332
  },
  {
    "doc": "corpus/seed/archi_assistkb_v0.html",
    "chunk_id": 0,
    "score": 0.279
  },
  {
    "doc": "corpus/seed/README.html",
    "chunk_id": 0,
    "score": 0.246
  },
  {
    "doc": "corpus/seed/rgpd_anonymisation_corpus.html",
    "chunk_id": 0,
    "score": 0.207
  }
],
"latency_ms": 8834,
"tokens": {
  "prompt": 1817,
  "completion": 187
}
PS C:\Users\Simohamed\Documents\assistkb-search-rag>

PS C:\Users\Simohamed\Documents\assistkb-search-rag> docker compose ps

```

| NAME         | IMAGE                   | COMMAND                  | SERVICE | CREATED        | STATUS        | PORTS                                                           |
|--------------|-------------------------|--------------------------|---------|----------------|---------------|-----------------------------------------------------------------|
| assistkb-api | assistkb-search-rag-api | "sh -c 'echo 'Wait!...'" | api     | 24 minutes ago | Up 24 minutes | 0.0.0.0:8000->8000/tcp, [::]:8000->8000/tcp                     |
| qdrant       | qdrant/qdrant:latest    | "/entrypoint.sh"         | qdrant  | 24 minutes ago | Up 24 minutes | 0.0.0.0:6333-6334->6333-6334/tcp, [::]:6333-6334->6333-6334/tcp |

```

PS C:\Users\Simohamed\Documents\assistkb-search-rag>

```

```

PS C:\Users\Simohamed\Documents\assistkb-search-rag> docker compose logs api --tail 15
assistkb-api | Indexing corpus...
assistkb-api | Ingestion...
assistkb-api | OK chunks generated: 7
assistkb-api | Embeddings...
assistkb-api | OK embeddings generated: 7
assistkb-api | Indexation Qdrant...
assistkb-api | Collection created
assistkb-api | Inserted 7 vectors
assistkb-api | Pipeline terminé
assistkb-api | Starting API...
assistkb-api | INFO: Started server process [56]
assistkb-api | INFO: Waiting for application startup.
assistkb-api | INFO: Application startup complete.
assistkb-api | INFO: Uvicorn running on http://0.0.0.0:8000 (Press CTRL+C to quit)
assistkb-api | INFO: 172.21.0.1:48034 - "POST /ask HTTP/1.1" 200 OK
PS C:\Users\Simohamed\Documents\assistkb-search-rag>

```